



RAPORT AL REZOLVĂRII PROBLEMEI SERVO FOLOSIND REȚELE NEURONALE ÎN PYTHON(MLP REGRESSOR)

Numele : Mocanu Vlad-Leonard

Grupa : 421A

1. PROBLEMA SERVO

În acest proiect se va rezolva problema sistemului Servo ce descrie un fenomen extrem de neliniar: prezicerea timpului de creștere a unui mecanism servo format dintr-un amplificator servo, un motor, un șurub de plumb și “un cărucior de alunecare”(a sliding carriage).

Datele furnizate sunt formate din 167 de exemple și 5 dimensiuni dintre care primele 2 reprezintă variabilele legăturii mecanice dintre motor și șurubul de plumb (“motor” și “screw”), următoarele 2 reprezintă variabilele amplificatorului (“pgain” și “vgain”), iar a 5-a dimensiune reprezintă timpul de creștere măsurat (“class”).

Conform arhivei, acest sistem este unul de regresie, prin urmare se va folosi un perceptron Multi-Strat de regresie pentru rezolvare.

Link problemă: <https://archive.ics.uci.edu/ml/datasets/Servo>

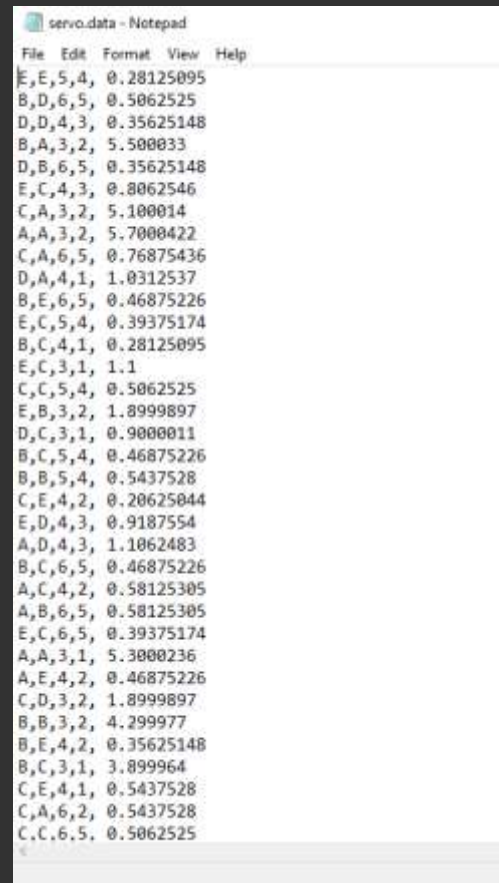
A sliding carriage:



1.1 OBSERVAȚIE


Observație: fișierul furnizat este in formatul “.data”, pentru ușurință l-am transformat in fișier excel cu extensia “.csv”.

fișier servo.data



```
servo.data - Notepad
File Edit Format View Help
E,E,5,4, 0.28125095
B,D,6,5, 0.5062525
D,D,4,3, 0.35625148
B,A,3,2, 5.500033
D,B,6,5, 0.35625148
E,C,4,3, 0.8062546
C,A,3,2, 5.100014
A,A,3,2, 5.7000422
C,A,6,5, 0.76875436
D,A,4,1, 1.0312537
B,E,6,5, 0.46875226
E,C,5,4, 0.39375174
B,C,4,1, 0.28125095
E,C,3,1, 1.1
C,C,5,4, 0.5062525
E,B,3,2, 1.8999897
D,C,3,1, 0.9000011
B,C,5,4, 0.46875226
B,B,5,4, 0.5437528
C,E,4,2, 0.20625044
E,D,4,3, 0.9187554
A,D,4,3, 1.1062483
B,C,6,5, 0.46875226
A,C,4,2, 0.58125305
A,B,6,5, 0.58125305
E,C,6,5, 0.39375174
A,A,3,1, 5.3000236
A,E,4,2, 0.46875226
C,D,3,2, 1.8999897
B,B,3,2, 4.299977
B,E,4,2, 0.35625148
B,C,3,1, 3.899964
C,E,4,1, 0.5437528
C,A,6,2, 0.5437528
C,C,6,5, 0.5062525
```

fișier servo.csv



	A	B	C	D	E	F	G
1	motor	screw	pgain	vgain	class		
2	E	E	5	4	0.281251		
3	B	D	6	5	0.506253		
4	D	D	4	3	0.356251		
5	B	A	3	2	5.500033		
6	D	B	6	5	0.356251		
7	E	C	4	3	0.806255		
8	C	A	3	2	5.100014		
9	A	A	3	2	5.700042		
10	C	A	6	5	0.768754		
11	D	A	4	1	1.031254		
12	B	E	6	5	0.468752		
13	E	C	5	4	0.393752		
14	B	C	4	1	0.281251		
15	E	C	3	1	1.1		
16	C	C	5	4	0.506253		
17	E	B	3	2	1.89999		
18	D	C	3	1	0.900001		
19	B	C	5	4	0.468752		
20	B	B	5	4	0.543753		
21	C	E	4	2	0.20625		
22	E	D	4	3	0.918755		
23	A	D	4	3	1.106248		
24	B	C	6	5	0.468752		
25	A	C	4	2	0.581253		
26	A	B	6	5	0.581253		
27	E	C	6	5	0.393752		
28	A	A	3	1	5.300024		
29	A	E	4	2	0.468752		
30	C	D	3	2	1.89999		
31	B	B	3	2	4.299977		
32	B	E	4	2	0.356251		
33	B	C	3	1	3.899964		
34	C	E	4	1	0.543753		
35	C	A	6	2	0.543753		
36	C	C	6	5	0.506253		
37	E	E	3	2	1.1		
38	E	E	3	1	0.9		

2. LIBRĂRII SI MODULE FOLOSITE

Librăria folosită pentru realizarea algoritmului este “scikit-learn”. In cadrul acestei librării au fost folosite modulele:

- neural_network (responsabilă pentru crearea perceptronului Multi-Strat(MLP)),
- train_test_split (pentru împărțirea datelor in variabile de antrenare(train) si de validare(test) in proporție 75%, 25%),
- metrics (pentru a calcula eroarea pătratică medie (MSE)(funcția loss) si scorul regresării pentru a valida performanța),

De asemenea, a fost folosită si libraria pandas pentru a prelucra fișierul inițial.

3. REZULTATE

Pentru măsurarea performanței am folosit modulul “metrics” din cadrul librării “scikit-learn”, mai exact funcția “metrics.r2_score(yValid, y_pred)” (scorul regresării), unde “yValid” reprezintă variabila ce conține etichetele de test, iar “ypred” reprezintă variabila ce conține etichetele prezise.

Variația parametrilor:

- numărul de straturi 1 sau 2
- numărul de neuroni pe stratul ascuns:
egal cu stratul anterior sau jumătate
- Learning rate: 0.1 sau 0.01

Variatia	Nr.straturi	Nr. neuroni	Valoare learning rate	Avg r2.score(10 iteratii valide) (medie aritmetica)
1	1	125	0.1	0.757
2	1	125	0.01	0.838
3	2	125, 125	0.1	0.769
4	2	125, 125	0.01	0.919
5	2	125, 62	0.1	0.73
6	2	125, 62	0.01	0.902